

Mining Anomalous Similarity-Based Association Rules as Exceptions to Dominant Rules Using Particle Swarm Optimization

Erik Fernando Casillas Velasco

Unidad Académica Monterrey

Centro de Investigación Científica y de Educación Superior de Ensenada

Monterrey, N.L., México

ecasillas@cicese.edu.mx

Resumen—Las reglas de asociación frecuentes describen regularidades, pero pueden ocultar desviaciones condicionadas dentro de esos mismos contextos. Este trabajo propone una metodología integrada basada en similitud y Particle Swarm Optimization (PSO): un primer enjambre descubre reglas dominantes y un segundo conserva su antecedente para buscar condiciones adicionales que conduzcan al consecuente opuesto. El método se evaluó sobre un conjunto cardiovascular de 70,000 observaciones con variables continuas y categóricas. La configuración dominante de 500 partículas produjo 1,742 familias no redundantes; 449 aparecieron en al menos dos semillas y 166 en las tres. Las salidas conservadas de la validación anómala contienen 15 familias para tres reglas dominantes seleccionadas, seis estables con confianza mínima de 0.60 y dos con confianza mínima de 0.70. Los resultados respaldan la viabilidad técnica de la integración pero, aun faltaría hacer mas analisis para corroborar que tan efectivo es la metodología planteada.

Index Terms—Minería de datos, reglas de asociación, reglas dominantes, reglas anómalas, reglas de excepción, similitud, Particle Swarm Optimization.

I. INTRODUCCIÓN

La minería de reglas de asociación busca identificar relaciones recurrentes entre atributos de grandes conjuntos de datos. En su formulación clásica, una regla $X \rightarrow Y$ se evalúa mediante medidas como soporte y confianza, que permiten distinguir patrones con evidencia suficiente de asociaciones accidentales [1]. Sin embargo, una descripción basada únicamente en patrones frecuentes puede ocultar subgrupos que se comportan de manera distinta dentro de un contexto aparentemente regular.

En este trabajo, una *regla dominante* es una regla fuerte que supera criterios definidos de soporte, confianza, *lift* y factor de certeza, y que se utiliza como regularidad de referencia. El término no implica que su antecedente cubra a la mayoría de la población. El interés principal recae en reglas anómalas o de excepción. Estas no se consideran útiles solo por ser raras: deben representar una desviación condicionada y confiable respecto a una regla dominante. La literatura relaciona las excepciones con una regla de sentido común o referencia [2], [3], [6], mientras que los trabajos sobre reglas anómalas

enfatan la desviación respecto al comportamiento esperado [4], [5], [14]. Aquí ambas ideas se concretan mediante

$$R_d : X \rightarrow Y, \quad R_a : X \wedge Z \rightarrow \neg Y, \quad (1)$$

donde Z introduce el contexto adicional de la excepción.

La coincidencia exacta también limita el tratamiento de atributos numéricos: observaciones próximas pueden separarse al discretizarse rígidamente. La minería basada en similitud permite sustituir la igualdad por grados continuos de activación [7]. Para explorar este espacio se emplea PSO, que actualiza soluciones candidatas a partir de la experiencia individual y colectiva del enjambre [8], [10].

La contribución consiste en integrar tres etapas: preparación de datos mixtos sin discretización rígida; descubrimiento mediante PSO de reglas dominantes basadas en similitud; y búsqueda condicionada de excepciones mediante un segundo PSO que optimiza únicamente Z . No se reivindica la creación individual de PSO, de las funciones de similitud ni de las reglas de excepción. El estudio evalúa cobertura, confiabilidad, contradicción, complejidad, redundancia y estabilidad, con un alcance exploratorio y sin inferencias clínicas.

II. TRABAJOS RELACIONADOS

Agrawal y Srikant establecieron el uso de soporte y confianza para seleccionar reglas frecuentes y confiables en datos transaccionales [1]. Para datos mixtos, Rodríguez-González *et al.* propusieron similitudes distintas de la igualdad con el fin de descubrir patrones frecuentes sin depender exclusivamente de coincidencias exactas [7]. El presente trabajo adopta ese principio, aunque utiliza funciones triangulares y gaussianas propias evaluadas directamente sobre cada registro.

Suzuki formuló las excepciones confiables como desviaciones asociadas con una regla común [2]; posteriormente se estudiaron el interés relativo y la relación con reglas positivas y negativas [3], [6]. Berzal *et al.* y Delgado *et al.* desarrollaron formulaciones para reglas anómalas y su relación con patrones dominantes [4], [5]. Ruiz *et al.* extendieron estas ideas a reglas difusas condicionadas y factores de certeza [14]. Estas fuentes respaldan la evaluación contextual, pero no la función objetivo exacta utilizada aquí.

PSO fue formulado inicialmente para espacios continuos [8]; Binary PSO transformó la velocidad en una probabilidad mediante una sigmoide [9]. En minería de reglas, Su *et al.* optimizan criterios de soporte antes de aplicar minería frecuente [11], mientras que Bernal-Baró *et al.* codifican reglas como partículas y utilizan exploración guiada [13]. Las variantes y riesgos de convergencia prematura se resumen en [10], [12]. En los trabajos revisados no se identificó una integración evaluada en dos enjambres donde las reglas dominantes basadas en similitud definan el espacio condicionado del segundo PSO.

III. MÉTODO PROPUESTO

III-A. Preparación del conjunto de datos

Sea $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$. Para cada atributo continuo j , $Q_j(p)$ denota su cuantil p e $IQR_j = Q_j(0.75) - Q_j(0.25)$. Con $\alpha = 0.0013499$, los límites híbridos y la normalización son

$$\begin{aligned} L_j &= \max\{Q_j(\alpha), Q_j(0.25) - 3IQR_j\}, \\ U_j &= \min\{Q_j(1 - \alpha), Q_j(0.75) + 3IQR_j\}, \\ \tilde{x}_{ij} &= \frac{\min\{U_j, \max\{L_j, x_{ij}\}\} - L_j}{U_j - L_j}. \end{aligned} \quad (2)$$

El procedimiento conserva las filas y reduce la influencia de extremos antes de llevar centros y radios a $[0, 1]$. Esta combinación de cuantiles y cercas de $3IQR$ es una decisión del trabajo; las variables categóricas conservan sus valores nominales.

III-B. Partícula mixta y activaciones

Una partícula representa el antecedente de una regla. Para un atributo continuo y uno categórico, respectivamente,

$$p_j^{\text{cont}} = (a_j, c_j, r_j), \quad p_k^{\text{cat}} = (a_k, q_k), \quad (3)$$

donde $a \in \{0, 1\}$ indica activación, $c_j \in [0, 1]$ es el centro, $r_j \in [0.02, 0.30]$ el radio y q_k una categoría observada. En la etapa dominante la partícula codifica X ; en la anómala, $X \rightarrow Y$ permanece fija y la partícula codifica únicamente Z .

Sea $d_{ij} = |\tilde{x}_{ij} - c_j|$. Las activaciones continuas son

$$\begin{aligned} A_j^\Delta(i) &= \max\left(0, 1 - \frac{d_{ij}}{r_j}\right), \\ A_j^G(i) &= \begin{cases} \exp[-\frac{1}{2}(d_{ij}/\sigma_j)^2], & d_{ij} < r_j, \\ 0, & d_{ij} \geq r_j, \end{cases} \quad \sigma_j = \frac{r_j}{3}. \end{aligned} \quad (4)$$

La función triangular facilita la interpretación lineal del intervalo; la gaussiana concentra la activación cerca del centro y se trunca en $3\sigma_j$. La relación $\sigma_j = r_j/3$ es una decisión de diseño, no una constante universal. Para categorías, $A_k(i; q_k) = 1$ si $x_{ik} = q_k$ y cero en otro caso. Las condiciones se combinan mediante la t-norma mínimo,

$$A_X(i) = \min_{C \in X} A_C(i), \quad (5)$$

de modo que la satisfacción del antecedente queda limitada por su condición menos satisfecha [14].




Figura 1. Activación triangular y gaussiana truncada en el espacio normalizado.

III-C. Métricas y fitness dominante

Sea $I_Y(i) \in \{0, 1\}$ el indicador del consecuente, con $\text{Supp}(X) = N^{-1} \sum_i A_X(i)$ y $\text{Supp}(Y) = N^{-1} \sum_i I_Y(i)$. El soporte conjunto, la confianza y el *lift* se definen como

$$\begin{aligned} \text{Supp}(X \wedge Y) &= \frac{1}{N} \sum_i \min(A_X(i), I_Y(i)), \\ \text{Conf}(X \rightarrow Y) &= \frac{\text{Supp}(X \wedge Y)}{\text{Supp}(X)}, \\ \text{Lift}(X \rightarrow Y) &= \frac{\text{Conf}(X \rightarrow Y)}{\text{Supp}(Y)}. \end{aligned} \quad (6)$$

Estas expresiones generalizan los conteos clásicos mediante grados de activación. El factor de certeza compara una confianza c con su frecuencia base b :

$$CF(c, b) = \begin{cases} (c - b)/(1 - b), & c > b, \\ (c - b)/b, & c < b, \\ 0, & c = b. \end{cases} \quad (7)$$

Para una regla dominante, $c = \text{Conf}(X \rightarrow Y)$, $b = \text{Supp}(Y)$ y $CF_d = CF(c, b)$. La función objetivo implementada es

$$\begin{aligned} F_d &= P_{\text{soporte}, d} \text{Conf}(X \rightarrow Y) CF_d^+ P_{\text{longitud}, d}, \\ P_{\text{soporte}, d} &= \min\left(1, \frac{\text{Supp}(X \wedge Y)}{\text{Supp}_{\min, d}}\right), \\ CF_d^+ &= \max(0, CF_d), \\ P_{\text{longitud}, d} &= \frac{1}{1 + |X|}. \end{aligned} \quad (8)$$

El producto exige evidencia, confiabilidad, incremento positivo respecto a la línea base y parsimonia. El soporte orienta soluciones subumbral, pero se satura al alcanzar el mínimo. Esta formulación es propia, inspirada en medidas de reglas y codificaciones PSO [1], [12], [13]. El *lift* se utiliza como filtro de aceptación, no dentro de F_d .

III-D. Actualización mediante PSO

Para cada dimensión numérica d , la velocidad se actualiza mediante

$$v_d^{t+1} = wv_d^t + c_1 u_1(p_d - x_d^t) + c_2 u_2(g_d - x_d^t), \quad (9)$$

con $u_1, u_2 \sim U(0, 1)$. Las velocidades se limitan mediante los valores $V_{\max}$ de la Tabla I. Centro y radio poseen velocidades independientes y se actualizan simultáneamente:

$$\begin{aligned} c_j^{t+1} &= \text{clip}(c_j^t + v_{c,j}^{t+1}, 0, 1), \\ r_j^{t+1} &= \text{clip}(r_j^t + v_{r,j}^{t+1}, r_{\min}, r_{\max}). \end{aligned} \quad (10)$$

La activación se obtiene con $P(a_j^{t+1} = 1) = S(v_{a,j}^{t+1})$, donde $S(v) = 1/(1 + e^{-v})$ [9]. Esta sigmoide decide la presencia de una condición; no mide similitud entre registros.

El valor categórico no se actualiza aritméticamente. Con probabilidad p_e se explora una categoría válida; en otro caso se elige entre el valor actual, p_{Best} y g_{Best} , con

$$\begin{aligned} \omega_t &= w, & \omega_p &= c_1 u_1, & \omega_g &= c_2 u_2, \\ \pi_s &= \frac{\omega_s}{\omega_t + \omega_p + \omega_g}, & s &\in \{t, p, g\}. \end{aligned} \quad (11)$$

Esta selección nominal es una adaptación propia que conserva la información cognitiva y social sin imponer un orden artificial entre categorías.

III-E. Búsqueda condicionada de anomalías

Para cada regla dominante $X \rightarrow Y$, el antecedente X se mantiene fijo y el segundo PSO optimiza únicamente un conjunto de condiciones adicionales Z . Las variables presentes en X se excluyen del espacio de búsqueda de Z , mientras que el consecuente se fija como $\neg Y$. La activación del antecedente condicionado se calcula mediante

$$A_{XZ}(i) = \min\{A_X(i), A_Z(i)\}. \quad (12)$$

El soporte de la excepción y las dos confianzas condicionadas se expresan en términos de soportes:

$$\begin{aligned} \text{Supp}_a &= \text{Supp}(X \wedge Z \wedge \neg Y), \\ \text{Conf}_X(Z \rightarrow \neg Y) &= \frac{\text{Supp}(X \wedge Z \wedge \neg Y)}{\text{Supp}(X \wedge Z)}, \\ \text{Conf}_X(\neg Y \rightarrow Z) &= \frac{\text{Supp}(X \wedge Z \wedge \neg Y)}{\text{Supp}(X \wedge \neg Y)}. \end{aligned} \quad (13)$$

En particular, el soporte anómalo se obtiene mediante los grados de activación:

$$\text{Supp}(X \wedge Z \wedge \neg Y) = \frac{1}{N} \sum_{i=1}^N \min\{A_{XZ}(i), I_{\neg Y}(i)\}. \quad (14)$$

La primera confianza mide la proporción de registros que presentan $\neg Y$ entre aquellos que satisfacen $X \wedge Z$. La segunda mide la concentración de Z entre los registros que contradicen la regla dominante dentro de X . Las frecuencias de referencia en el contexto dominante son

$$\begin{aligned} \text{Supp}_X(\neg Y) &= \frac{\text{Supp}(X \wedge \neg Y)}{\text{Supp}(X)}, \\ \text{Supp}_X(Z) &= \frac{\text{Supp}(X \wedge Z)}{\text{Supp}(X)}. \end{aligned} \quad (15)$$

Así, $\text{Supp}_X(\neg Y)$ representa la frecuencia base de los fallos de la regla dominante dentro de X , mientras que $\text{Supp}_X(Z)$

representa la frecuencia de la condición adicional en ese mismo contexto. Para comparar cada confianza con su respectiva frecuencia base se define

$$\Delta_X(U, V) = \text{Conf}_X(U \rightarrow V) - \text{Supp}_X(V). \quad (16)$$

El factor de certeza condicionado se calcula mediante

$$CF_X(U \rightarrow V) = \begin{cases} \frac{\Delta_X(U, V)}{1 - \text{Supp}_X(V)}, & \Delta_X(U, V) > 0, \\ \frac{\Delta_X(U, V)}{\text{Supp}_X(V)}, & \Delta_X(U, V) < 0, \\ 0, & \Delta_X(U, V) = 0. \end{cases} \quad (17)$$

Las dos instancias utilizadas para evaluar una regla candidata son

$$\begin{aligned} CF_{\text{dir}} &= CF_X(Z \rightarrow \neg Y), \\ CF_{\text{inv}} &= CF_X(\neg Y \rightarrow Z). \end{aligned} \quad (18)$$

El factor directo determina si Z incrementa la presencia de $\neg Y$ dentro de X . El factor inverso determina si Z aparece con mayor concentración entre los fallos de la regla dominante. En la rama positiva que contribuye al fitness, ambos factores equivalen a:

$$\begin{aligned} CF_{\text{dir}} &= \frac{\text{Conf}_X(Z \rightarrow \neg Y) - \text{Supp}_X(\neg Y)}{1 - \text{Supp}_X(\neg Y)}, \\ CF_{\text{inv}} &= \frac{\text{Conf}_X(\neg Y \rightarrow Z) - \text{Supp}_X(Z)}{1 - \text{Supp}_X(Z)}. \end{aligned} \quad (19)$$

La función objetivo para las reglas anómalas se define como

$$\begin{aligned} F_a &= P_{\text{soporte},a} CF_{\text{dir}}^+ CF_{\text{inv}}^+ P_{\text{longitud},a}, \\ P_{\text{soporte},a} &= \min\left(1, \frac{\text{Supp}_a}{\text{Supp}_{\min,a}}\right), \\ CF_{\text{dir}}^+ &= \max(0, CF_{\text{dir}}), \\ CF_{\text{inv}}^+ &= \max(0, CF_{\text{inv}}), \\ P_{\text{longitud},a} &= \frac{1}{1 + |Z|}. \end{aligned} \quad (20)$$

El componente $P_{\text{soporte},a}$ favorece excepciones con evidencia suficiente y se satura al alcanzar el soporte mínimo. Los factores CF_{dir}^+ y CF_{inv}^+ conservan únicamente incrementos positivos respecto a las frecuencias de referencia dentro de X . Finalmente, $P_{\text{longitud},a}$ penaliza condiciones adicionales demasiado específicas. Esta formulación constituye una decisión metodológica del presente trabajo, inspirada en criterios de confiabilidad, desviación respecto de una regla dominante y parsimonia considerados en la minería de reglas difusas de excepción y anomalía [5], [14].

III-F. Redundancia y flujo algorítmico

Dos reglas aceptadas se comparan mediante sus vectores de activación $\mathbf{A}, \mathbf{B} \in [0, 1]^N$:

$$J(\mathbf{A}, \mathbf{B}) = \frac{\sum_i \min(A(i), B(i))}{\sum_i \max(A(i), B(i))}. \quad (21)$$

En la etapa dominante solo se comparan reglas con igual consecuente, método de similitud y conjunto de variables; en la anómala se comparan dentro de cada regla dominante. Las reglas con $J \geq 0.85$ forman una familia y se conserva la de mayor fitness. El umbral es una decisión experimental.




Figura 2. Flujo resumido de la metodología integrada.

IV. CONFIGURACIÓN EXPERIMENTAL

Se utilizó el *Cardiovascular Disease Dataset* de Kaggle [15], con 70,000 registros y 13 columnas. Tras eliminar el identificador y convertir la edad de días a años, se conservaron cinco atributos continuos (edad, altura, peso y presiones sistólica y diastólica), seis categóricos (sexo, colesterol, glucosa, fumador, alcohol y actividad física) y el objetivo cardiovascular binario. No se detectaron valores ausentes ni se eliminaron filas.

El experimento dominante combinó dos consecuentes y dos funciones de similitud con tres semillas, para 12 ejecuciones. La parada se fijó por iteraciones. La comparación de 50, 100 y 500 partículas fue exploratoria y mantuvo 50 iteraciones y la parada se fijó por iteraciones.

En la exploración anómala se evaluaron 166 familias dominantes de estabilidad alta y tres soportes mínimos, equivalentes a 498 ejecuciones con la semilla 55. Los umbrales de confianza de 0.60, 0.70 y 0.80 se aplicaron *post hoc*: después de ejecutar PSO se utilizaron para filtrar y clasificar el mismo conjunto de reglas. Por tanto, no modifican la trayectoria del enjambre ni representan búsquedas independientes. Para la validación se eligieron RD_0810 y RD_0703 por alcanzar confianza anómala de al menos 0.70, y RD_0467 por presentar el mayor fitness.

V. RESULTADOS Y DISCUSIÓN

V-A. Preparación y reglas dominantes

El recorte modificó 1,847 de 350,000 valores continuos (0.53 %). Las presiones sistólica y diastólica concentraron 1,424 modificaciones (77.10 %); se describen como valores fuera de los límites híbridos, no como errores de captura. La clase estaba equilibrada de forma natural: 34,979 registros con cardio y 35,021 sin cardio; no se aplicó remuestreo.

Con 500 partículas se obtuvieron 4,754 $pBest$ válidos de 6,000 posibles. La consolidación paramétrica dejó 4,725 reglas y Jaccard produjo 1,742 familias. De estas, 449 aparecieron en al menos dos semillas: 166 con estabilidad alta y 283 media; 1,293 quedaron como exploratorias.

La Fig. 3 muestra que el aumento del enjambre coincidió con más familias y una mayor proporción reproducible: 4.43 %, 7.31 % y 25.77 % para 50, 100 y 500 partículas. Las medianas de confianza fueron 0.811896, 0.836649 y 0.856892, respectivamente.

La Tabla II ilustra el tipo de regla encontrado.

V-B. Reglas anómalas

El barrido guardado produjo 215 $pBest$ aceptados asociados con siete reglas dominantes. Después de Jaccard quedaron 11 familias iniciales y ninguna alcanzó confianza 0.80. La validación de tres reglas seleccionadas produjo 15 familias; seis, asociadas con dos reglas dominantes, aparecieron en al menos dos semillas con confianza mínima de 0.60 y dos conservaron confianza mínima de 0.70. Las nueve restantes aparecieron en una sola semilla.

RA_001 y RA_002 alcanzaron masas equivalentes de 155.284 y 112.387 observaciones, respectivamente. Estas cantidades no son conteos exactos de pacientes porque provienen de activaciones continuas. Las asociaciones solo ejemplifican el funcionamiento del método y no demuestran causalidad ni validez clínica

Cuadro I
CONFIGURACIÓN EXPERIMENTAL CONSOLIDADA.

Etapas	Partículas	Iteraciones	Semillas	Supp _{mín}	Conf _{mín}	Longitud
Dominante	500	50	55, 13, 33	0.01	0.60	$1 \leq X \leq 4$
Anómala	35	40	55; 101–103	0.0005; 0.001; 0.002	0.60; 0.70; 0.80	$1 \leq Z \leq 3$

Parámetros comunes: $w = 0.70$, $c_1 = c_2 = 1.50$, $V_{\text{máx},a} = 4.0$, $V_{\text{máx},c} = 0.20$, $V_{\text{máx},r} = 0.10$, $p_e = 0.10$, $r \in [0.02, 0.30]$ y $J_{\text{mín}} = 0.85$.
Criterios dominantes: Lift > 1.00 y $CF_d \geq 0.10$.




Figura 3. Cantidad y proporción de familias dominantes según el tamaño del enjambre. La comparación es exploratoria.

Cuadro II
REGLAS DOMINANTES REPRESENTATIVAS CON DOS CONDICIONES.

ID	Regla	Supp	Conf	Lift	CF	F_d	Sem.
RD_0308	sistólica $180.77 \pm 17.50 \wedge$ glucosa normal $\rightarrow$ cardio=sí	.010041	.879775	1.760607	.759695	.222787	3
RD_0734	sistólica $90.90 \pm 10.60 \wedge$ colesterol normal $\rightarrow$ cardio=no	.012781	.848666	1.696314	.697151	.197216	3

Cuadro III
PAREJAS DOMINANTE–EXCEPCIÓN ESTABLES CON CONFIANZA MÍNIMA DE 0.70.

ID	Dominante	$X \rightarrow Y$	Condición adicional Z	Supp _a	Conf.	Conf. inv.	Sem.
RA_001	RD_0810	sistólica 110.25 ± 9.62 , gaussiana $\rightarrow$ cardio=no	colesterol muy alto $\wedge$ glucosa normal $\wedge$ no fumador	.002218	.766362	.070446	4
RA_002	RD_0703	sistólica 103.63 ± 14.58 , triangular $\rightarrow$ cardio=no	colesterol muy alto $\wedge$ glucosa normal $\wedge$ no fumador	.001606	.710790	.067749	2

VI. CONCLUSIONES

Se desarrolló una metodología integrada para preparar datos mixtos, representar condiciones continuas y categóricas, descubrir reglas dominantes mediante similitud y buscar excepciones con un segundo PSO. La etapa anómala conserva el contexto dominante y optimiza únicamente las condiciones adicionales, sin recurrir a una discretización rígida.

El experimento dominante produjo familias que cumplieron criterios de soporte, confianza, *lift*, factor de certeza y complejidad. La consolidación paramétrica y Jaccard difuso redujeron la redundancia. En la etapa anómala, dos familias conservaron confianza mínima de 0.70 en al menos dos semillas. Los resultados respaldan la viabilidad técnica de $X \wedge Z \rightarrow \neg Y$, sin demostrar aún la robustez general del método.

REFERENCIAS

- [1] R. Agrawal and R. Srikant, "Fast algorithms for mining association rules in large databases," in *Proc. 20th Int. Conf. Very Large Data Bases (VLDB)*, 1994, pp. 487–499.
- [2] E. Suzuki, "Autonomous discovery of reliable exception rules," in *Proc. 3rd Int. Conf. Knowledge Discovery and Data Mining (KDD-97)*, 1997, pp. 259–262.
- [3] F. Hussain, H. Liu, E. Suzuki, and H. Lu, "Exception rule mining with a relative interestingness measure," in *Knowledge Discovery and Data Mining: Current Issues and New Applications*, LNAI 1805. Springer, 2000, pp. 86–97, doi: 10.1007/3-540-45571-X_11.
- [4] F. Berzal, J.-C. Cubero, N. Marín, and M. Gámez, "Anomalous association rules," in *IEEE ICDM Workshop on Alternative Techniques for Data Mining and Knowledge Discovery*, 2004.
- [5] M. Delgado, M. D. Ruiz, and D. Sánchez, "New approaches for discovering exception and anomalous rules," *Int. J. Uncertainty, Fuzziness and Knowledge-Based Systems*, vol. 19, no. 2, pp. 361–399, 2011, doi: 10.1142/S0218488511007039.
- [6] D. Taniar, W. Rahayu, V. C. S. Lee, and O. Daly, "Exception rules in association rule mining," *Applied Mathematics and Computation*, vol. 205, no. 2, pp. 735–750, 2008, doi: 10.1016/j.amc.2008.05.020.
- [7] A. Y. Rodríguez-González, J. F. Martínez-Trinidad, J. A. Carrasco-Ochoa, and J. Ruiz-Shulcloper, "Mining frequent patterns and association rules using similarities," *Expert Systems with Applications*, vol. 40, no. 17, pp. 6823–6836, 2013, doi: 10.1016/j.eswa.2013.06.041.
- [8] J. Kennedy and R. Eberhart, "Particle swarm optimization," in *Proc. ICNN'95*, vol. 4, 1995, pp. 1942–1948, doi: 10.1109/ICNN.1995.488968.
- [9] J. Kennedy and R. C. Eberhart, "A discrete binary version of the particle swarm algorithm," in *Proc. IEEE Int. Conf. Systems, Man, and Cybernetics*, vol. 5, 1997, pp. 4104–4108, doi: 10.1109/ICSMC.1997.637339.
- [10] F. Marini and B. Walczak, "Particle swarm optimization (PSO). A tutorial," *Chemometrics and Intelligent Laboratory Systems*, vol. 149, pt. B, pp. 153–165, 2015, doi: 10.1016/j.chemolab.2015.08.020.
- [11] T. Su, H. Xu, and X. Zhou, "Particle Swarm Optimization-Based Association Rule Mining in Big Data Environment," *IEEE Access*, vol. 7, pp. 161008–161016, 2019, doi: 10.1109/ACCESS.2019.2951195.
- [12] G. Li, T. Wang, Q. Chen, P. Shao, N. Xiong, and A. V. Vasilakos, "A survey on particle swarm optimization for association rule mining," *Electronics*, vol. 11, no. 19, Art. no. 3044, 2022, doi: 10.3390/electronics11193044.
- [13] G. Bernal-Baró, J. F. Martínez-Trinidad, R. M. Valdovinos-Rosas, J. A. Carrasco-Ochoa, A. Y. Rodríguez-González, and M. S. Lazo-Cortés, "A PSO-based algorithm for mining association rules using a guided exploration strategy," *Pattern Recognition Letters*, vol. 138, pp. 8–15, 2020, doi: 10.1016/j.patrec.2020.05.006.
- [14] M. D. Ruiz, D. Sánchez, M. Delgado, and M. J. Martín-Bautista, "Discovering fuzzy exception and anomalous rules," *IEEE Transactions on Fuzzy Systems*, vol. 24, no. 4, pp. 930–944, 2016, doi: 10.1109/TFUZZ.2015.2489240.
- [15] S. Ulianova, "Cardiovascular Disease Dataset," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>. [Accessed: Aug. 6, 2026].